DELIMITACIÓN DEL PROBLEMA DE CLASIFICACIÓN Y TIPO DE DATOS

Selección Automática de Características en Algoritmos de Clasificación Mediante Algoritmos Genéticos y Métodos de Envoltorio con Apache Spark RDD

1. INTRODUCCIÓN

Este documento tiene como objetivo establecer y delimitar de manera precisa el trabajo que se abordará en el presente Trabajo Fin de Máster (TFM). Se definen los límites del problema de investigación, los tipos de datos a utilizar, las restricciones metodológicas y técnicas, y los objetivos específicos que guiarán el desarrollo del trabajo. Esta delimitación es fundamental para enmarcar adecuadamente el alcance del proyecto y establecer expectativas claras sobre los resultados esperados.

La selección automática de características representa uno de los desafíos fundamentales en el aprendizaje automático moderno, especialmente cuando se trabaja con conjuntos de datos de alta dimensionalidad. Este documento establece la delimitación formal del problema de clasificación que se abordará en este TFM, definiendo el alcance, los tipos de datos, las restricciones y los objetivos específicos de la investigación.

El problema central que aborda esta investigación es la selección eficiente de subconjuntos óptimos de características para mejorar el rendimiento de algoritmos de clasificación supervisada, utilizando algoritmos genéticos (AG) como método de búsqueda y métodos de envoltorio (wrapper methods) como estrategia de evaluación, todo ello implementado sobre Apache Spark RDD para aprovechar el procesamiento distribuido.

2. DEFINICIÓN FORMAL DEL PROBLEMA

2.1. Problema de Selección de Características

Sea $X = \{x_1, x_2, ..., x_n\}$ un conjunto de N instancias (muestras) en un espacio de características de dimensión D, donde:

- N representa el número total de instancias o muestras en el conjunto de datos
- Cada instancia $x_i \in \mathbb{R}^D$ es un vector de D características numéricas
- Cada instancia x_i tiene asociada una etiqueta de clase $y_i \in C = \{c_1, c_2, ..., c_k\}$
- K representa el número de clases distintas en el problema de clasificación

El problema de selección de características consiste en encontrar un subconjunto óptimo $S \subseteq F = \{f_1, f_2, ..., f^p\}$ de características tal que:

$$S^* = \text{argmin } J(S)$$

donde J(S) es una función objetivo que combina:

- Precisión del clasificador: Error de clasificación E(S) medido mediante validación cruzada

- Cardinalidad del subconjunto: |S|, que mide la complejidad del modelo

Esta formulación corresponde a un problema de optimización multiobjetivo NP-completo, donde la evaluación de cada candidato requiere entrenar y validar un clasificador con N instancias, D características y K clases (Guyon & Elisseeff, 2003). La complejidad computacional crece exponencialmente con D (2^D posibles subconjuntos), lo que justifica el uso de algoritmos evolutivos y procesamiento distribuido mediante Spark.

2.2. Enfoque de Métodos de Envoltorio con Algoritmos Genéticos

Los métodos de envoltorio utilizan el rendimiento del clasificador como función de evaluación directa. En este TFM, se emplearán algoritmos genéticos como estrategia de búsqueda global debido a su capacidad demostrada para explorar eficientemente espacios de búsqueda exponenciales (2^D posibles subconjuntos).

Representación cromosómica: Cada solución candidata se codifica como un vector binario $b = [b_1, b_2, ..., b^D]$ donde $b_j = 1$ indica la inclusión de la característica f_j en el subconjunto S.

Función de fitness: Para cada cromosoma b, el fitness se calcula como:

$$\text{Fitness}(b) = \alpha \times \text{Accuracy}(b) - \beta \times (|S| / D)$$

donde α y β son parámetros que balancean precisión y parsimonia del modelo. La evaluación de Accuracy(b) requiere entrenar un clasificador usando únicamente las características seleccionadas sobre las N instancias y medir su rendimiento mediante k-fold cross-validation.

3. TIPOS DE DATOS Y DOMINIOS DE APLICACIÓN

3.1. Características Generales de los Conjuntos de Datos

Esta investigación se enfocará en problemas de clasificación supervisada con características exclusivamente numéricas. La selección estratégica de datasets permite evaluar el enfoque propuesto tanto en escenarios de clasificación binaria (K=2) como multiclase (K>2), abarcando diferentes niveles de dimensionalidad y tamaño para un análisis exhaustivo de escalabilidad:

Característica	**Descripción**
Dimensionalidad (D)	Baja (D=30) a muy alta (D=5,000)
Tamaño de muestra (N)	Desde N=452 hasta N=7,000 instancias
Número de clases (K)	K=2 (binario) y K=16 (multiclase)
Tipos de características	Exclusivamente numéricas (continuas)
Relación N/D	Desde N>>D (favorable) hasta N≈D (desafiante)

3.2. Datasets Seleccionados: Justificación Metodológica

Para este TFM se ha optado por limitar la experimentación a 3 datasets representativos, cada uno con un rol específico en la evaluación del sistema. Esta decisión metodológica se fundamenta en los siguientes principios:

- **Profundidad:** Se prioriza la realización de un análisis más exhaustivo sobre un número bajo de datasets.
- **Viabilidad temporal:** Cada dataset requiere múltiples ejecuciones del AG, ajuste de hiperparámetros, análisis de escalabilidad y validación estadística.
- **Cobertura representativa:** Los datasets seleccionados cubren clasificación binaria y multiclase, baja y alta dimensionalidad.
- **Benchmark establecido:** Todos los datasets son ampliamente citados en la literatura de feature selection con AG.

La selección de datasets se limitará, salvo causa justificada, a los tres que se citan a continuación. Los tres datasets seleccionados son:

Dataset	N	D	K	Tipo	Dominio
WDBC	569	30	2	Binario	Diagnóstico cáncer de mama
Arrhythmia	452	279	16	Multiclase	Clasificación de arritmias cardíacas
Gisette	7,000	5,000	2	Binario	Dígitos manuscritos 4 vs 9 (NIPS 2003)

3.2.1. Justificación Detallada de la Selección

Dataset 1: WDBC - Wisconsin Diagnostic Breast Cancer (Pruebas Rápidas)

Rol: Dataset para desarrollo, debugging y establecimiento de baseline.

Especificaciones: N=569 instancias (357 benignas, 212 malignas), D=30 características numéricas continuas, K=2 clases (Maligno/Benigno).

Justificación técnica:

- Dimensionalidad baja (D=30) que permite iteraciones rápidas del AG durante la fase de desarrollo y debugging del algoritmo.
- Relación favorable N/D (N>>D) que facilita el entrenamiento de clasificadores base sin riesgo de overfitting.
- Dataset de referencia en la literatura de feature selection con GA (Aalaei et al., 2016; Jeyasingh & Veluchamy, 2017), permitiendo comparar resultados.
- Alta correlación entre algunas características (radio, perímetro, área) que permite evaluar la capacidad del GA para identificar redundancia.
- Coste computacional bajo del wrapper: permite múltiples ejecuciones para ajuste de hiperparámetros del AG.

Fuente: UCI Machine Learning Repository - https://archive.ics.uci.edu/dataset/17/breast+cancer+wisconsin+diagnostic (Street et al., 1993)

Dataset 2: UCI Arrhythmia (Principal - Multiclase)

Rol: Dataset principal para evaluación de clasificación multiclase y selección de características en alta dimensionalidad relativa.

Especificaciones: N=452 instancias, D=279 características (206 numéricas, 73 nominales), K=16 clases (Normal + 15 tipos de arritmia).

Justificación técnica:

- Único dataset multiclase (K=16), permitiendo evaluar el comportamiento del AG-wrapper en problemas de clasificación complejos más allá del caso binario.
- Alta dimensionalidad (D=279) con espacio de búsqueda de 2^{279} subconjuntos, justificando el uso de algoritmos evolutivos.
- Relación desafiante N/D (N<D) que representa escenarios reales de alta dimensionalidad en dominios biomédicos.
- Amplio uso en literatura de feature selection con métodos wrapper y GA (Mustaqeem et al., 2018; Ayar et al., 2023).
- Presencia de características redundantes e irrelevantes que el GA debe identificar y eliminar.
- Desbalance de clases: permite evaluar métricas como Macro-F1 y la robustez del método.

Fuente: UCI Machine Learning Repository - https://archive.ics.uci.edu/dataset/5/arrhythmia (Guvenir et al., 1997)

Dataset 3: Gisette (Escalabilidad con Spark)

Rol: Dataset para demostrar la necesidad y efectividad del procesamiento distribuido con Spark RDD.

Especificaciones: N=7,000 instancias, D=5,000 características (2,500 reales + 2,500 probes/ ruido), K=2 clases (dígitos 4 vs 9).

Justificación técnica:

- Muy alta dimensionalidad (D=5,000) con espacio de búsqueda de 2^{5000} subconjuntos, haciendo imprescindible la paralelización.
- Dataset del NIPS 2003 Feature Selection Challenge: benchmark estándar ampliamente citado en literatura académica.
- Contiene 2,500 características de ruido deliberadamente añadidas.
- Coste computacional muy alto del wrapper (7,000 × 5,000 = 35M operaciones por evaluación), justificando plenamente Spark RDD.
- Permite medir speed-up y eficiencia de paralelización con diferentes configuraciones (1, 2, 4, 8 ejecutores).

Fuente: UCI Machine Learning Repository - https://archive.ics.uci.edu/dataset/170/gisette (Guyon et al., 2004)

3.2.2. Cobertura de Casos de Uso y Análisis de Coste Computacional

La selección de estos tres datasets proporciona una cobertura sistemática de los escenarios clave para evaluar el sistema propuesto:

- **WDBC** representa problemas típicos de ML con dimensionalidad manejable, similar a datasets del mundo real en medicina, finanzas e IoT.
- **Arrhythmia** representa el caso intermedio con clasificación multiclase y el desafío de N<D típico de biomedicina.
- **Gisette** representa el caso extremo de alta dimensionalidad típico de bioinformática, análisis de imágenes y reconocimiento de patrones.

La siguiente tabla presenta el análisis comparativo del coste computacional del método wrapper:

Dataset	Espacio de búsqueda	Coste por evaluación	Necesidad de Spark
WDBC	$2^{30} \approx 10^9$ subconjuntos	Bajo (569 × 30)	Opcional (baseline)
Arrhythmia	2^{279} subconjuntos	Medio (452 × 279)	Recomendado
Gisette	2^{5000} subconjuntos	Muy alto (7,000 × 5,000)	Imprescindible

3.2.3. Estrategia de Análisis

Con esta selección de 3 datasets, el tiempo disponible permite realizar un análisis exhaustivo que incluye:

- Análisis de sensibilidad de parámetros del AG (tamaño de población, probabilidades de cruce/mutación, criterios de parada).
- Comparación rigurosa de múltiples clasificadores base (Naive Bayes, SVM, Random Forest).
- Evaluación en clasificación binaria (WDBC, Gisette) y multiclase (Arrhythmia).
- Estudio de convergencia y estabilidad del AG mediante múltiples ejecuciones independientes.
- Análisis detallado de las características seleccionadas consistentemente.
- Mediciones precisas de escalabilidad con diferentes configuraciones de Spark (1, 2, 4, 8 ejecutores).
- Validación estadística robusta (tests de significancia, intervalos de confianza, índice de Jaccard para estabilidad).

3.3. Preprocesamiento y Normalización de Datos

3.3.1. Delimitación a Características Numéricas

Este TFM se enfoca exclusivamente en datasets con características numéricas (continuas y discretas), excluyendo deliberadamente variables categóricas. Esta delimitación se justifica por las siguientes razones académicas y técnicas:

- Foco en alta dimensionalidad: Los datasets de alta dimensionalidad típicamente estudiados en feature selection (Madelon, Arcene, Gisette) son predominantemente numéricos. Guyon & Elisseeff (2003) en su trabajo seminal utilizan datasets con características numéricas estandarizadas.
- Complejidad del encoding categórico: La conversión de variables categóricas a representaciones numéricas (one-hot encoding, polynomial contrasts) introduce complejidades adicionales. Kuhn & Johnson (2019) dedican un capítulo completo (Capítulo 5) al encoding categórico, señalando que 'most models require that all predictors be numeric' y que el encoding puede inflar artificialmente la dimensionalidad.
- Consideraciones en contexto distribuido: El manejo de variables categóricas en entornos distribuidos con Spark RDD requiere estrategias específicas de particionamiento y agregación que están fuera del alcance central de esta investigación.
- Concentración en el objetivo principal: El foco del TFM es la selección automática de características mediante AG-wrapper methods y su implementación distribuida, no el preprocesamiento de datos categóricos.

Esta decisión metodológica es consistente con la práctica estándar en la literatura de feature selection, donde los experimentos se realizan típicamente sobre características numéricas preprocesadas (Guyon et al., 2002; Liu et al., 2018; Huang et al., 2020).

3.3.2. Estandarización de Características

Todas las características numéricas serán estandarizadas mediante normalización Z-score antes de la aplicación de los algoritmos de selección. Esta transformación es crítica por las siguientes razones:

- Comparabilidad entre características: Las características pueden tener escalas y rangos muy diferentes. Por ejemplo, en datos médicos, la edad (rango 0-100) y niveles de glucosa (rango 70-200 mg/dL) no son directamente comparables. La estandarización coloca todas las características en la misma escala.
- Requisito de algoritmos basados en distancia: Clasificadores como SVM y k-NN son sensibles a las escalas de las características. Sin normalización, características con mayor varianza dominarían el cálculo de distancias.
- Justificación académica: Guyon & Elisseeff (2003) señalan explícitamente que 'Because the abundance of mRNA varies by several orders of magnitude depending on the gene, the variables are usually standardized'. Esta práctica es estándar en feature selection.

La transformación Z-score se define como:

$$z = \frac{x - \mu}{\sigma}$$

donde μ es la media y σ la desviación estándar de la característica calculadas sobre el conjunto de entrenamiento. Los parámetros de estandarización (μ, σ) se calculan únicamente sobre el conjunto de entrenamiento y se aplican posteriormente al conjunto de validación/ prueba para evitar data leakage.

3.3.3. Pipeline de Preprocesamiento

El pipeline completo de preprocesamiento seguirá esta secuencia:

- Carga de datos: Lectura del dataset desde UCI Repository

- Manejo de valores faltantes: Imputación por media (características continuas) o moda (características discretas), si aplica
- Separación train/test: División estratificada 70/30 preservando la distribución de clases
- Estandarización: Cálculo de parámetros (μ, σ) en train, aplicación a train y test
- Distribución con Spark: Particionamiento del dataset estandarizado en RDDs para procesamiento distribuido

Este pipeline garantiza la reproducibilidad de los experimentos y previene filtraciones de información del conjunto de prueba al conjunto de entrenamiento (Kuhn & Johnson, 2019).

4. CLASIFICADORES BASE PARA MÉTODOS DE ENVOLTORIO

La selección del clasificador base es crítica en métodos wrapper, ya que cada evaluación de fitness requiere entrenar y validar el modelo. En un esquema GA-wrapper, el clasificador se ejecuta miles de veces durante la evolución (una vez por cada individuo de la población, en cada generación, con k-fold cross-validation). Por tanto, la elección debe balancear tres criterios fundamentales (Kuhn & Johnson, 2019):

- **Velocidad de entrenamiento:** Esencial dado el alto número de evaluaciones. Un clasificador lento convierte el proceso en inviable incluso con paralelización.
- **Representatividad:** El clasificador debe reflejar adecuadamente la calidad del subconjunto de características evaluado.

Robustez: Capacidad de manejar diferentes subconjuntos de características sin degradación extrema del rendimiento.

4.1. Justificación de la Selección de Clasificadores

Dado que el foco principal de este TFM es la demostración de cómo la paralelización con Spark RDD permite ejecutar de forma eficiente el proceso de selección de características mediante algoritmos genéticos, se ha optado por limitar los clasificadores base a dos. Esta decisión se fundamenta en las siguientes razones:

1. **Foco en la contribución principal:** El objetivo del TFM no es comparar clasificadores, sino demostrar la eficiencia del sistema GA-wrapper distribuido. Dos clasificadores con perfiles computacionales distintos son suficientes para validar el enfoque.
2. **Contraste computacional:** Un clasificador rápido (Naive Bayes) y otro más costoso (SVM) permiten evaluar el beneficio de la paralelización en diferentes regímenes de coste por evaluación.
3. **Viabilidad temporal:** Con 4 meses de desarrollo, dedicar tiempo a ajustar y analizar cuatro clasificadores restaría profundidad al análisis de escalabilidad y paralelización.
4. **Precedente en la literatura:** La combinación Naive Bayes + SVM como clasificadores base en GA-wrapper es frecuente en la literatura, proporcionando resultados comparables y complementarios (Özbabalık et al., 2016; Aalaei et al., 2016).

4.2. Clasificador Primario: Naive Bayes (Gaussian)

Rol: Clasificador base durante la ejecución del algoritmo genético (evaluación de fitness).

Fundamento

El clasificador Naive Bayes se fundamenta en el teorema de Bayes con la suposición de independencia condicional entre las características. Para características numéricas continuas, se emplea la variante Gaussian Naive Bayes, donde la distribución de cada característica dada la clase se modela como una distribución normal. Su complejidad de entrenamiento es $O(N \times D)$, lo que lo convierte en uno de los clasificadores más rápidos disponibles.

Ventajas para el Contexto del TFM

- **Entrenamiento extremadamente rápido:** Complejidad $O(N \times D)$ lineal. Esto es crítico cuando el GA evalúa cientos de individuos por generación con 5-fold CV, generando miles de entrenamientos por ejecución.
- **Robusto en alta dimensionalidad:** No sufre la maldición de la dimensionalidad gracias a la asunción de independencia. Funciona bien incluso con subconjuntos aleatorios de características durante las primeras generaciones del GA.
- **Sin hiperparámetros complejos:** No requiere ajuste de parámetros (a diferencia de SVM), eliminando una fuente de variabilidad en los experimentos.
- **Bajo overhead computacional:** Ideal para iteraciones del AG, ya que la señal de fitness se obtiene rápidamente, permitiendo al GA explorar el espacio de búsqueda eficientemente.

Ampliamente validado: Referente en GA-wrapper feature selection (Huang et al., 2020; Aalaei et al., 2016; Rashid & Abdullah, 2014).

4.3. Clasificador Secundario: SVM (Kernel Lineal)

Rol: Clasificador para validación de resultados y demostración del beneficio de paralelización con Spark.

Fundamento

Las Máquinas de Vectores de Soporte (SVM) construyen un hiperplano de margen máximo para separar las clases. Se emplea el kernel lineal por su equilibrio entre rendimiento y eficiencia: su complejidad de entrenamiento es aproximadamente $O(N \times D)$ a $O(N^2 \times D)$ dependiendo de la implementación, significativamente mayor que Naive Bayes en la práctica, especialmente con validación cruzada.

Ventajas para el Contexto del TFM

- **Excelente rendimiento en alta dimensionalidad:** SVM con kernel lineal es especialmente efectivo cuando D es grande en relación a N (caso de Arrhythmia y Gisette), ya que maximiza el margen de separación sin necesidad de mapeo a espacios de mayor dimensión.
- **Mayor coste computacional que NB:** Este mayor coste es una ventaja para el TFM, ya que permite demostrar de forma más clara el speed-up obtenido con la paralelización en Spark. Cuando cada evaluación de fitness es más costosa, la distribución del trabajo entre nodos produce ganancias más visibles.

- **Hiperparámetro controlado:** Con kernel lineal, solo se ajusta el parámetro de regularización C (a diferencia del kernel RBF que requiere además γ), manteniendo la complejidad experimental manejable.
- **Disponibilidad en Spark MLlib:** Spark MLlib incluye SVMWithSGD (SVM con Stochastic Gradient Descent) compatible con RDDs, lo que facilita la integración con la arquitectura distribuida del TFM.
- **Referencia en la literatura:** Ampliamente utilizado como clasificador base en GA-wrapper methods (Liu et al., 2018; Gokulnath & Shantharajah, 2019; Gao et al., 2025).

4.5. Estrategia de Implementación

La estrategia de uso de los clasificadores se organiza en dos fases complementarias:

Fase 1 — Búsqueda con el AG (Naive Bayes)

Naive Bayes actúa como clasificador base durante todo el proceso evolutivo del AG. Su velocidad de entrenamiento permite maximizar el número de generaciones y el tamaño de población dentro de los límites temporales de cada ejecución. El fitness de cada cromosoma se calcula como la accuracy obtenida mediante 5-fold cross-validation con Gaussian Naive Bayes. Esta fase constituye el núcleo del sistema GA-wrapper y es donde la paralelización con Spark RDD produce el mayor impacto al distribuir la evaluación de fitness de la población entre los nodos del cluster.

Fase 2 — Validación y Análisis de Escalabilidad (SVM)

Una vez que el AG ha convergido y se ha obtenido el subconjunto óptimo de características S*, se evalúa su rendimiento con SVM (kernel lineal) para: (1) confirmar que la calidad de la selección no depende del clasificador usado durante la búsqueda; (2) proporcionar un punto de comparación con un clasificador de mayor capacidad discriminativa; y (3) demostrar el beneficio de la paralelización con Spark en escenarios de mayor coste computacional por evaluación.

Adicionalmente, se ejecutará el proceso completo del GA usando SVM como clasificador wrapper en el dataset Gisette, para medir directamente el speed-up y la eficiencia de paralelización cuando el coste por evaluación es alto. Esta comparación NB-secuencial vs NB-Spark vs SVM-secuencial vs SVM-Spark proporciona una matriz completa de análisis de escalabilidad.

Estimación de Evaluaciones de Fitness

La siguiente tabla muestra la estimación del número total de evaluaciones de fitness para una ejecución típica del AG:

Parámetro	WDBC	Arrhythmia	Gisette	Fórmula
Tamaño población (P)	50	100	100	-
Generaciones (G)	50	100	100	-
Folds CV (k)	5	5	5	-
Entrenamientos totales	12,500	50,000	50,000	$P \times G \times k$

Estas cifras subrayan la necesidad de clasificadores rápidos durante la búsqueda y de procesamiento distribuido para datasets de gran dimensionalidad.

5. MÉTRICAS DE EVALUACIÓN

5.1. Métricas de Rendimiento del Clasificador

Para evaluar la calidad de los subconjuntos de características seleccionados, se utilizarán las siguientes métricas estándar:

- Accuracy: Proporción de predicciones correctas (métrica principal para datasets balanceados)
- Precision, Recall, F1-Score: Métricas balanceadas para clases desbalanceadas
- AUC-ROC: Área bajo la curva ROC, para evaluar discriminación en clasificación binaria
- Macro-averaged F1: Para problemas multiclase, promediando F1-score de todas las clases

5.2. Métricas de Calidad de la Selección

- Número de características seleccionadas: $|S^*|$ como medida de parsimonia
- Tasa de reducción: $(D - |S^*|) / D \times 100\%$
- Estabilidad: Índice de Jaccard entre múltiples ejecuciones para medir consistencia

5.3. Métricas de Eficiencia Computacional

- Tiempo total de ejecución: Wall-clock time del proceso completo de selección
- Speed-up: Comparación entre implementación secuencial y distribuida (Spark)
- Número de evaluaciones de fitness: Cantidad de entrenamientos de clasificadores realizados
- Eficiencia de paralelización: Análisis de escalabilidad con diferentes números de nodos

6. RESTRICCIONES Y CONSIDERACIONES

6.1. Restricciones Técnicas

- Uso exclusivo de Apache Spark RDD: La implementación debe utilizar RDDs (no DataFrames/ML) para explorar los fundamentos del procesamiento distribuido
- Lenguaje de implementación: Python (PySpark) con scikit-learn para clasificadores base
- Biblioteca de AG: DEAP (Distributed Evolutionary Algorithms in Python) adaptada para Spark
- Validación: k-fold cross-validation (k=5 por defecto) para todas las evaluaciones

6.2. Consideraciones de Escalabilidad

El enfoque distribuido con Spark RDD introduce desafíos específicos:

- Overhead de comunicación: La serialización y transmisión de poblaciones entre nodos puede ser costosa
- Balance de carga: Es necesario distribuir equitativamente las evaluaciones de fitness
- Sincronización: Los operadores genéticos (selección, cruce, mutación) requieren coordinación entre generaciones

6.3. Limitaciones del Alcance

Este TFM NO abordará:

- Métodos de filtro (filter methods): El enfoque se centra exclusivamente en wrappers
- Métodos embedded: Se consideran fuera del alcance de esta investigación
- Variables categóricas: Se excluyen deliberadamente para concentrar esfuerzos en la selección de características numéricas
- Ingeniería de características: No se crearán nuevas características, solo selección
- Deep Learning: Los clasificadores se limitarán a métodos tradicionales de ML
- Datos no estructurados: Únicamente datos tabulares numéricos

7. OBJETIVOS ESPECÍFICOS DEL PROBLEMA

Dados los tipos de datos y restricciones establecidas, los objetivos específicos son:

7.1. Objetivo Primario

Desarrollar e implementar un sistema de selección automática de características basado en algoritmos genéticos y métodos de envoltorio, optimizado para ejecución distribuida en Apache Spark RDD, que demuestre mejoras significativas en:

- Precisión de clasificación comparada con usar todas las características
- Reducción de dimensionalidad (≥ 50% de características eliminadas)
- Tiempo de ejecución mediante paralelización (speed-up ≥ 2x con 4 nodos)

7.2. Objetivos Secundarios

- Comparar el rendimiento entre Naive Bayes, SVM y Random Forest como clasificadores base en wrapper methods
- Analizar la escalabilidad del enfoque en función de la dimensionalidad (30 a 10,000+ características)
- Evaluar la estabilidad y reproducibilidad de las características seleccionadas
- Identificar patrones de características relevantes en diferentes dominios (médico, señales, dígitos)
- Documentar las mejores prácticas para implementar algoritmos evolutivos sobre Spark RDD

8. REFERENCIAS

Kuhn, M., & Johnson, K. (2019). Feature Engineering and Selection: A Practical Approach for Predictive Models. CRC Press. Disponible en: http://www.feat.engineering/

Kuhn, M., & Johnson, K. (2013). Applied Predictive Modeling. Springer. DOI: 10.1007/978-1-4614-6849-3

Guyon, I., & Elisseeff, A. (2003). An introduction to variable and feature selection. Journal of Machine Learning Research, 3, 1157-1182.

Guyon, I., Weston, J., Barnhill, S., & Vapnik, V. (2002). Gene selection for cancer classification using support vector machines. Machine Learning, 46(1-3), 389-422.

Goldberg, D. E. (1989). Genetic Algorithms in Search, Optimization, and Machine Learning. Addison-Wesley.

Mitchell, M. (1998). An Introduction to Genetic Algorithms. MIT Press.

Liu, X.-Y., et al. (2018). A Hybrid Genetic Algorithm With Wrapper-Embedded Approaches for Feature Selection. IEEE Access, 6, 22863-22874.

Huang, J., et al. (2020). GARS: Genetic Algorithm for the identification of a Robust Subset of features in high-dimensional datasets. BMC Bioinformatics, 21(54).

Gao, J., Li, J., & Zang, W. (2025). A hybrid high-dimensional feature selection method integrating an improved genetic algorithm and fuzzy neural network. AIP Advances, 15(11), 115023.

UCI Machine Learning Repository. (2024). Disponible en: https://archive.ics.uci.edu/

Dua, D., & Graff, C. (2019). UCI Machine Learning Repository. Irvine, CA: University of California, School of Information and Computer Science.

James, G., et al. (2021). An Introduction to Statistical Learning (2nd Edition). Springer. Disponible en: https://www.statlearning.com/

Hastie, T., Tibshirani, R., & Friedman, J. (2009). The Elements of Statistical Learning (2nd Edition). Springer. Disponible en: https://hastie.su.domains/ElemStatLearn/

Apache Spark Documentation. (2024). RDD Programming Guide. Disponible en: https://spark.apache.org/docs/latest/rdd-programming-guide.html